

Bagging y Random Forests

Métodos de Ensamble en Machine Learning

Fabio Mavric

Universidad Privada del Valle

18 de junio de 2026

Contenido

- 1 Introducción
- 2 Bagging
- 3 Random Forests
- 4 Comparación
- 5 Aplicaciones
- 6 Conclusiones

¿Qué es un Método de Ensamble?

- Un método de ensamble combina múltiples modelos de aprendizaje para mejorar el rendimiento predictivo.
- La idea principal es que varios modelos débiles o moderados pueden producir mejores resultados que uno solo.
- Entre los métodos de ensamble más conocidos se encuentran:
 - Bagging (Bootstrap Aggregating)
 - Random Forests
 - Boosting

¿Qué es Bagging?

Bagging (Bootstrap Aggregating) es una técnica de ensamble propuesta por Leo Breiman en 1996.

Su objetivo es:

- Reducir la varianza del modelo.
- Mejorar la estabilidad de las predicciones.
- Disminuir el riesgo de sobreajuste.

Se utiliza especialmente con modelos inestables como los árboles de decisión.

¿Cómo Funciona Bagging?

- 1 Se generan múltiples muestras Bootstrap del conjunto de datos.
- 2 Se entrena un árbol de decisión independiente para cada muestra.
- 3 Se combinan las predicciones:
 - Clasificación: votación mayoritaria.
 - Regresión: promedio de predicciones.

$$Predicción\ Final = \frac{1}{n} \sum_{i=1}^n Modelo_i$$

Muestreo Bootstrap

- Se seleccionan observaciones aleatoriamente con reemplazo.
- Algunas observaciones pueden repetirse.
- Otras pueden no ser seleccionadas.

Datos Originales	Muestra Bootstrap
A	A
B	C
C	B
D	C
E	E

Cada árbol recibe una muestra distinta.

Ventajas de Bagging

- Reduce la varianza.
- Mejora la precisión predictiva.
- Disminuye el sobreajuste.
- Fácil de paralelizar.
- Funciona bien con árboles de decisión.

¿Qué es Random Forest?

Random Forest es una extensión de Bagging desarrollada por Leo Breiman en 2001.

Consiste en:

- Construir muchos árboles de decisión.
- Utilizar muestras Bootstrap.
- Seleccionar aleatoriamente un subconjunto de variables en cada división del árbol.

Esta aleatoriedad adicional genera árboles menos correlacionados.

Datos de Entrenamiento



Muestras Bootstrap



Árboles de Decisión



Selección Aleatoria de Variables



Votación / Promedio

Selección Aleatoria de Variables

En cada nodo:

- No se evalúan todas las variables.
- Se selecciona aleatoriamente un subconjunto.
- Se elige la mejor división dentro de ese subconjunto.

Ejemplo:

Si existen 20 variables:

$$m = \sqrt{20} \approx 4$$

Solo se evalúan aproximadamente 4 variables en cada división.

Importancia de Variables

Una ventaja importante de Random Forest es que permite medir la importancia de cada variable.

Ejemplo:

Variable	Importancia
Edad	35 %
Ingreso	28 %
Experiencia	22 %
Educación	15 %

Esto facilita la interpretación del modelo.

Ventajas de Random Forest

- Alta precisión.
- Menor riesgo de sobreajuste.
- Maneja datos con muchas variables.
- Tolera valores faltantes y ruido.
- Permite medir importancia de variables.
- Funciona para clasificación y regresión.

Desventajas de Random Forest

- Mayor costo computacional.
- Menor interpretabilidad que un árbol único.
- Puede requerir ajuste de hiperparámetros.
- Consume más memoria cuando existen muchos árboles.

Bagging vs Random Forest

Característica	Bagging	Random Forest
Bootstrap	Sí	Sí
Árboles múltiples	Sí	Sí
Selección aleatoria de variables	No	Sí
Reducción de correlación	Baja	Alta
Precisión	Buena	Muy alta
Importancia de variables	Limitada	Sí

Random Forest se utiliza en:

- Predicción de riesgo crediticio.
- Diagnóstico médico.
- Detección de fraude.
- Predicción de accidentes.
- Clasificación de imágenes.
- Segmentación de clientes.

Es uno de los algoritmos más utilizados en Ciencia de Datos.

Ejemplo Aplicado

Problema:

- Predecir si un conductor tendrá un accidente.

Variables:

- Edad.
- Antigüedad de licencia.
- Historial de siniestros.
- Tipo de vehículo.
- Zona geográfica.

Random Forest combina cientos de árboles para estimar la probabilidad de accidente con mayor precisión.

- Bagging mejora la estabilidad y reduce la varianza.
- Random Forest amplía Bagging mediante selección aleatoria de variables.
- Produce modelos robustos y precisos.
- Es ampliamente utilizado en problemas de clasificación y regresión.
- Constituye una herramienta fundamental en Machine Learning moderno.

¡Gracias por su atención!