

Cochabamba, Bolivia

# Random Forests

---

Estudiante: **Fabio Mavric**

Materia: Big Data — TI24

Dataset: Cardiovascular Disease (Kaggle)

Fecha: Junio 2025

# Índice

---

|                                                 |           |
|-------------------------------------------------|-----------|
| <b>1. Introducción</b>                          | <b>2</b>  |
| <b>2. Fundamentos Teóricos</b>                  | <b>2</b>  |
| 2.1. Bagging (Bootstrap Aggregating)            | 2         |
| 2.2. Random Forest                              | 3         |
| 2.3. Criterio de División: Impureza de Gini     | 3         |
| 2.4. Importancia de Variables                   | 3         |
| <b>3. Dataset y Análisis Exploratorio (EDA)</b> | <b>3</b>  |
| 3.1. Descripción del Dataset                    | 4         |
| 3.2. Variables del Dataset                      | 4         |
| 3.3. Hallazgos del Análisis Exploratorio        | 4         |
| <b>4. Preprocesamiento de Datos</b>             | <b>5</b>  |
| 4.1. Pipeline Aplicado                          | 5         |
| 4.2. Resultados del Preprocesamiento            | 6         |
| <b>5. Modelo Principal: Random Forest</b>       | <b>6</b>  |
| 5.1. Configuración del Modelo                   | 6         |
| 5.2. Resultados Obtenidos                       | 7         |
| 5.3. Importancia de Variables                   | 7         |
| <b>6. Comparación de Modelos</b>                | <b>8</b>  |
| 6.1. Modelo de Referencia: Decision Tree        | 8         |
| 6.2. Resultados Comparativos                    | 8         |
| 6.3. Análisis de la Curva ROC                   | 8         |
| <b>7. Discusión y Conclusiones</b>              | <b>9</b>  |
| 7.1. Interpretación de Resultados               | 9         |
| 7.2. Conclusiones                               | 10        |
| 7.3. Limitaciones                               | 10        |
| 7.4. Trabajo Futuro                             | 10        |
| <b>Referencias</b>                              | <b>10</b> |

## 1. Introducción

---

El presente informe documenta el desarrollo completo de un proyecto de aprendizaje automático aplicado a la predicción de enfermedades cardiovasculares, con énfasis en la implementación y evaluación del algoritmo **Random Forest**, un método de *ensemble* basado en la técnica de *Bagging* (Bootstrap Aggregating).

Las enfermedades cardiovasculares representan una de las principales causas de mortalidad a nivel mundial. Contar con modelos predictivos precisos permite a los profesionales de la salud identificar pacientes en riesgo de manera temprana y tomar decisiones clínicas más fundamentadas.

El proyecto sigue una metodología estructurada en cuatro etapas: análisis exploratorio de datos (EDA), preprocesamiento, entrenamiento del modelo principal y comparación con un modelo de referencia. Cada etapa fue implementada en un notebook independiente de Python utilizando la biblioteca `scikit-learn`.

### Objetivo del Proyecto

Entrenar y evaluar un modelo **Random Forest** para clasificar pacientes como sanos o con enfermedad cardiovascular, y comparar su desempeño frente a un árbol de decisión simple (*Decision Tree*) usando métricas estándar de clasificación.

## 2. Fundamentos Teóricos

---

### 2.1. Bagging (Bootstrap Aggregating)

El *Bagging*, introducido por Breiman [1], es una técnica de *ensemble* que reduce la varianza de un modelo inestable entrenando múltiples instancias sobre muestras generadas con reemplazo (*bootstrap*) del conjunto original. La predicción final se obtiene combinando las salidas individuales:

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x) \quad (1)$$

donde  $B$  es el número de modelos entrenados y  $\hat{f}^{*b}$  es el modelo entrenado sobre la  $b$ -ésima muestra bootstrap.




Figura 1: Esquema del algoritmo Bagging aplicado a árboles de decisión.

## 2.2. Random Forest

El algoritmo *Random Forest* [2] extiende el Bagging con una modificación crucial: en cada nodo de cada árbol, el split no evalúa todas las  $p$  variables disponibles, sino solo un subconjunto aleatorio de tamaño  $m$ :

$$m = \sqrt{p} \quad (\text{clasificación}) \quad (2)$$

Esta aleatorización **decorrelaciona** los árboles entre sí. Si los árboles fueran idénticos, promediarlos no reduciría la varianza. Al introducir diversidad, el promedio es sustancialmente más estable que cualquier árbol individual.

## 2.3. Criterio de División: Impureza de Gini

En cada nodo, el algoritmo elige la variable y el umbral que maximizan la reducción de la impureza de Gini:

$$G = 1 - \sum_{k=1}^K p_k^2 \quad (3)$$

donde  $p_k$  es la proporción de la clase  $k$  en el nodo. Un nodo puro ( $G = 0$ ) contiene únicamente muestras de una misma clase.

## 2.4. Importancia de Variables

La importancia de una variable  $X_j$  se estima como el promedio de la reducción de impureza que genera a lo largo de todos los árboles y todos los nodos donde se usa:

$$\text{Importance}(X_j) = \frac{1}{B} \sum_{b=1}^B \sum_{\substack{t \in T_b: \\ \text{split en } X_j}} \Delta G_t \quad (4)$$

## 3. Dataset y Análisis Exploratorio (EDA)

---

### 3.1. Descripción del Dataset

Se utilizó el *Cardiovascular Disease Dataset* disponible en Kaggle [5], un conjunto de datos clínicos con las siguientes características:

#### Resultados EDA — Notebook 01

|                              |                                        |
|------------------------------|----------------------------------------|
| <b>Total de registros:</b>   | 70,000 pacientes                       |
| <b>Variables originales:</b> | 12 (+ 2 derivadas en EDA = 14 totales) |
| <b>Clase 0 (Sano):</b>       | 35,021 registros (50.0 %)              |
| <b>Clase 1 (Enfermo):</b>    | 34,979 registros (50.0 %)              |
| <b>Outliers detectados:</b>  | Sí, en presión arterial                |
| <b>Correlaciones clave:</b>  | ap_hi, cholesterol, age                |

El balance entre clases es prácticamente perfecto (50.0 % vs 50.0 %), lo que elimina la necesidad de técnicas de sobremuestreo y garantiza que las métricas como accuracy sean representativas del rendimiento real del modelo.




Figura 2: Balance de clases en el dataset cardiovascular. El dataset está perfectamente balanceado (50 % / 50 %).

### 3.2. Variables del Dataset

### 3.3. Hallazgos del Análisis Exploratorio

El análisis exploratorio reveló tres hallazgos relevantes:

- **Outliers en presión arterial:** Se detectaron valores fisiológicamente imposibles (p.ej., presión sistólica  $< 0$  o  $> 300$  mmHg), lo que requirió un paso de limpieza específico.
- **Correlaciones clave:** Las variables `ap_hi` (presión sistólica), `cholesterol` y `age` mostraron la mayor correlación con la variable objetivo `cardio`.
- **Balance perfecto de clases:** Con exactamente 50 %/50 %, no se necesitó submuestreo ni sobremuestreo del dataset.

Cuadro 1: Descripción de las variables del dataset.

| Variable    | Tipo       | Descripción                        |
|-------------|------------|------------------------------------|
| age         | Numérica   | Edad en días (convertida a años)   |
| height      | Numérica   | Altura en centímetros              |
| weight      | Numérica   | Peso en kilogramos                 |
| ap_hi       | Numérica   | Presión arterial sistólica (mmHg)  |
| ap_lo       | Numérica   | Presión arterial diastólica (mmHg) |
| gender      | Categórica | 1 = Mujer, 2 = Hombre              |
| cholesterol | Ordinal    | 1 = Normal, 2 = Alto, 3 = Muy alto |
| gluc        | Ordinal    | 1 = Normal, 2 = Alto, 3 = Muy alto |
| smoke       | Binaria    | 0 = No fumador, 1 = Fumador        |
| alco        | Binaria    | 0 = No bebe, 1 = Bebe alcohol      |
| active      | Binaria    | 0 = Sedentario, 1 = Activo         |
| cardio      | Target     | 0 = Sano, 1 = Enfermedad cardíaca  |




Figura 3: Correlación de cada variable con `cardio`. La presión sistólica (`ap_hi`) y la edad son los predictores más importantes.

## 4. Preprocesamiento de Datos

### 4.1. Pipeline Aplicado

El preprocesamiento siguió un pipeline secuencial de cinco pasos:

Figura 4: Pipeline de preprocesamiento aplicado al dataset cardiovascular.

**Limpieza de outliers.** Se aplicaron filtros con criterios fisiológicos para eliminar registros con valores imposibles:  $60 \leq \text{ap\_hi} \leq 250$  mmHg,  $40 \leq \text{ap\_lo} \leq 200$  mmHg,

$120 \leq \text{height} \leq 220$  cm, y la condición lógica  $\text{ap\_hi} \geq \text{ap\_lo}$ .

**Feature Engineering.** Se construyeron dos variables derivadas con relevancia clínica:

- $\text{IMC} = \frac{\text{peso}}{(\text{altura}/100)^2}$
- $\text{Presión de pulso} = \text{ap\_hi} - \text{ap\_lo}$

**Encoding y Scaling.** La variable de grupo etario fue codificada con `LabelEncoder`. Las variables numéricas continuas fueron estandarizadas con `StandardScaler`:  $z = \frac{x - \mu}{\sigma}$ .

## 4.2. Resultados del Preprocesamiento

### Resultados Preprocesamiento — Notebook 02

|                                   |                                   |
|-----------------------------------|-----------------------------------|
| <b>Conjunto de entrenamiento:</b> | 54,894 filas (80 %)               |
| <b>Conjunto de prueba:</b>        | 13,724 filas (20 %)               |
| <b>Proporción 80/20:</b>          | ✓ Verificada                      |
| <b>Balance en Train:</b>          | Clase 0: 27,737   Clase 1: 27,157 |
| <b>Balance en Test:</b>           | Clase 0: 6,935   Clase 1: 6,789   |

El split estratificado garantiza que la proporción de clases en cada partición refleje la del dataset completo, evitando sesgos de muestreo en la evaluación.

## 5. Modelo Principal: Random Forest

### 5.1. Configuración del Modelo

El modelo fue configurado con los siguientes hiperparámetros:

Listing 1: Configuración del Random Forest en scikit-learn.

```

1 from sklearn.ensemble import RandomForestClassifier
2
3 rf_model = RandomForestClassifier(
4     n_estimators = 200,           # Numero de arboles
5     max_depth    = 12,           # Profundidad maxima por arbol
6     min_samples_split = 10,      # Minimo de muestras para un split
7     min_samples_leaf = 5,        # Minimo de muestras en hoja
8     max_features = 'sqrt',       # m = sqrt(p) features por split
9     class_weight  = 'balanced',  # Manejo de clases
10    random_state  = 42,
11    n_jobs        = -1            # Todos los nucleos
12 )

```

La selección `max_features='sqrt'` implementa la aleatoriedad de features característica del Random Forest: en cada nodo, solo se evalúan  $m = \sqrt{14} \approx 3,7 \approx 4$  variables de las 14 disponibles.

## 5.2. Resultados Obtenidos

### Resultados Random Forest — Notebook 03

| Métrica              | Valor                |
|----------------------|----------------------|
| Accuracy (Test)      | <b>73.25 %</b>       |
| F1-Score             | <b>0.7203</b>        |
| AUC-ROC              | <b>0.7975</b>        |
| CV Accuracy (5-Fold) | 73,40 % $\pm$ 0,35 % |




Figura 5: Accuracy por fold en la validación cruzada 5-fold. La línea naranja indica el promedio (73,40 %  $\pm$  0,35 %), mostrando alta estabilidad entre folds.

## 5.3. Importancia de Variables

### Importancia de Variables — Random Forest




Figura 6: Importancia de variables calculada como la reducción promedio de la impureza de Gini. `ap_hi`, `age` y `ap_lo` son los tres predictores más relevantes.

## 6. Comparación de Modelos

### 6.1. Modelo de Referencia: Decision Tree

Para cuantificar la ganancia del ensemble, se entrenó un árbol de decisión simple con los mismos hiperparámetros de profundidad (`max_depth=12`) como modelo de referencia (*baseline*).

### 6.2. Resultados Comparativos

| Comparación Final — Notebook 04 |          |          |         |          |               |
|---------------------------------|----------|----------|---------|----------|---------------|
| Modelo                          | Accuracy | F1-Score | AUC-ROC | CV Mean  | CV Std        |
| Decision Tree                   | 71.22 %  | 0.7051   | 0.7672  | 71.32 %  | $\pm 0.18 \%$ |
| Random Forest                   | 73.25 %  | 0.7203   | 0.7975  | 73.40 %  | $\pm 0.35 \%$ |
| Mejora RF                       | +2.03 pp | +0.015   | +0.030  | +2.08 pp | —             |




Figura 7: Comparación de métricas entre Decision Tree y Random Forest. El Random Forest supera al árbol individual en todas las métricas evaluadas.

### 6.3. Análisis de la Curva ROC

La métrica AUC-ROC cuantifica la capacidad del modelo de discriminar entre clases a diferentes umbrales de clasificación. Un valor de  $AUC = 0,5$  equivale a una clasificación aleatoria, mientras que  $AUC = 1,0$  representa discriminación perfecta.




Figura 8: Curva ROC comparativa. El Random Forest (AUC = 0.7975) domina sobre el Decision Tree (AUC = 0.7672), especialmente en tasas bajas de FPR, que son las más relevantes clínicamente.

## 7. Discusión y Conclusiones

### 7.1. Interpretación de Resultados

Los resultados obtenidos confirman las predicciones teóricas sobre el comportamiento del algoritmo Bagging:

1. **Reducción de varianza:** El Random Forest logra una accuracy un 2.03 puntos porcentuales superior al árbol individual (73.25 % vs 71.22 %), efecto directo de promediar 200 árboles decorrelacionados.
2. **Mejor discriminación:** La ganancia más relevante es en AUC-ROC (+0.030), que mide la capacidad discriminativa real del modelo. Un AUC de 0.7975 indica que el modelo distingue correctamente entre sano y enfermo en el 79.75 % de los pares posibles.
3. **Alta estabilidad:** La desviación estándar en validación cruzada ( $\pm 0.35$  %) confirma que el modelo generaliza de manera consistente, sin sobreajuste al conjunto de entrenamiento.
4. **Presión arterial como predictor dominante:** La variable `ap_hi` concentra el 18.2 % de la importancia total, seguida por la edad (15.5 %) y la presión diastólica (14.8 %). Este hallazgo es coherente con la evidencia clínica sobre los factores de riesgo cardiovascular.

## 7.2. Conclusiones

- ✓ **Random Forest supera al árbol individual** en todas las métricas: Accuracy (+2.03 pp), F1-Score (+0.015) y AUC-ROC (+0.030).
- ✓ **La aleatoriedad de features** (`max_features='sqrt'`) es el ingrediente clave que decorrelaciona los árboles y hace más efectivo el promedio de Bagging.
- ✓ **El balance de clases** (50 %/50 %) permitió evaluar el modelo sin sesgos; el parámetro `class_weight='balanced'` reforzó este comportamiento durante el entrenamiento.
- ✓ **La validación cruzada** (73,40 % $\pm$ 0,35 %) confirma que el modelo es estable y generalizable a datos no vistos.

## 7.3. Limitaciones

- El modelo es una *caja negra*: no es directamente interpretable como un árbol individual.
- La accuracy de 73.25 % tiene margen de mejora con optimización sistemática de hiperparámetros (`GridSearchCV`) o con modelos de boosting.
- El dataset no incluye variables clínicas adicionales como ECG, biomarcadores o historial familiar, que podrían mejorar significativamente la predicción.

## 7.4. Trabajo Futuro

- Optimización de hiperparámetros con `GridSearchCV` o `RandomizedSearchCV`.
- Comparación con modelos de *boosting*: XGBoost y Gradient Boosting.
- Implementación de SHAP Values para explicabilidad a nivel de instancia.
- Incorporación de técnicas de selección de features para reducir dimensionalidad.

## Referencias

---

## Referencias

---

- [1] Breiman, L. (1996). *Bagging predictors*. Machine Learning, 24(2), 123–140. <https://doi.org/10.1007/BF00058655>
- [2] Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

- [3] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning* (2nd ed.). Springer. Capítulo 8: Tree-Based Methods.
- [4] Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media. Capítulo 7: Ensemble Learning and Random Forests.
- [5] Sulianova (2019). *Cardiovascular Disease Dataset*. Kaggle. <https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset>